





PROYECTO MACHINE LEARNING:

PREDICCIÓN DE ACCIDENTES EN MONTAÑA

ARRATE ALDUCIN ARRILUCEA

DANILO CASTILLO

RICARDO DÍAZ COCA





ÍNDICE

- Índice
- Introducción
- Tipo de problema
- Target
- Explicación del dataset
- Baseline
- Odd Ratios
- Algunas conclusiones
- Proximos pasos



INTRODUCCIÓN

La Federación Madrileña de Montañismo ofrece una tarjeta federativa que además de la membresía y la posibilidad de competir en los deportes de montaña por madrid, ofrece un seguro de vida para las prácticas o competencias. El proyecto se basa en predecir los posibles accidentes entre los federados para el año 2026.

Estas predicciones, ayudaran a la federación a entender los riesgos que supone cada tarjeta federativa, tanto así como insights para usarlo en campañas de marketing, segmentación de públicos, negociación con las aseguradoras, etc.



A QUE TIPO DE PROBLEMA NOS ENFRENTAMOS?

En este caso nos enfrentamos a un **problema de clasificación**. Dado que la respuesta que obtendremos será si tendrá o no un accidente, se trata de una clasificación binaria.

En este caso el target lo creamos nosotros a través de la información recogida desde 2 datasets: el del listado de federados, y el de partes de accidente entre el 2020 y el 2025.




TARGET


La variable target se creo contando la cantidad de siniestros en el lapso del data set. Esta misma cuenta la cantidad de siniestros que ha sufrdo cada federado desde el 2020 al 2025.

Nos enfrentamos a una de los escenarios no deseados: el del target desbalanceado, lo que luego nos llevará a probar distintas maneras de subsanar para conseguir mejores métricas de predicción.

Proporción de siniestros



EXPLORACION DEL DATASET



En este caso, el dataset finalmente utilizado partió de distintas fuentes de datos, por un lado el listado de federados anuales y por otro lado el listado de los siniestros de cada año. Al juntarlos pudimos crear la variable target, y además ver la evolución de los siniestros, es decir, los accidentes año a año de forma general y particular.

En este gráfico podemos ver la distribución en años de la cantidad de federados, y de la proporción de siniestros por año. **La suba en los años de la pandemia se da porque a quienes tenían la licencia federativa, se les permitía salir a la montaña.** De ahí la mayor proporción de accidentes en ese lapso.



Como partimos de un dataset creado a partir de otros, la selección de variables fue uno de los focos en el tratado del dataset. Podemos ver aquí el **listado inicial de variables con la que contaba nuestro data set.**

Dado que al unir lo datasets la cantidad de federados no cuada con la de siniestros en el año, se generaron **muchos campos con NaNs.**

Otra cosa que pudimos ver fue que **mucha información correspondía más al lado cualitativo nominal**, por lo que no aportaba mucha información. Esto se heredó del data set del listado de federados, dado que es un listado de las personas federadas, datos nominales y algunos ordinales.


Lo mismo se replicó en el dataset de los siniestros, dado que aportaban detalles sobre cada siniestro, pero no sobre los federados que sufrieron estos.

...

	data_type	valores_nulos	valores_unicos	cardinalidad_ptg
nsocio	numerica	0.0	36959	30.48
codigopostaldomicilio	categorica	0.0	1635	1.35
numeroclub	categorica	0.0	181	0.15
modalidad	categorica	0.0	15	0.01
categoria	categorica	0.0	10	0.01
discapacidad	categorica	0.0	113	0.09
numeroaccidentesaño	numerica	0.0	4	0.0
helicoptero	numerica	0.0	1	0.0
hospitalizacion	numerica	0.0	2	0.0
target	numerica	0.0	2	0.0
accidenteshistoricos	numerica	0.0	9	0.01
edad	numerica	0.0	91	0.08
temporada_federado	numerica	0.0	6	0.0
Actividad	categorica	85.2	29	0.02
Lugar	categorica	85.7	2467	2.03
Provincia	categorica	85.2	53	0.04
TipoAccidente	categorica	85.2	103	0.08
DescripcionGrado	categorica	85.8	3	0.0
TamañoGrupo	numerica	85.2	58	0.05
NResponsables	numerica	85.2	21	0.02
Entrenamiento	categorica	85.2	2	0.0
ActividadPersonal	categorica	85.2	2	0.0
ActividadOrganizada	categorica	85.2	2	0.0
Festivo	categorica	85.2	2	0.0
año_accidente	numerica	85.2	6	0.0

Una de las variables que pueden aportar más valor a nuestro modelo es la de modalidad. Esta variable señala la licencia federativa elegida por los federados. Se diferencian por modalidades de competición, y de cobertura, ya sea autonómica, a nivel país, mundo y luego montaña de hasta y por arriba de los 7000 metros.

Sobre esta distribución podemos inferir una lógica de que a mayor cobertura, mayor es el peligro de cobtraer un accidente. En esta manera de verlo, es lógico que el senderismo sea la actividad de menor riesgo.



Luego de algunas transformaciones, llegamos al data frame en el que comenzaríamos nuestro featurring engeneering.

In [24]:

df_model # Mostramos el dataframe final para comprobar que todo tiene sentido

Out[24]:

	nsocio	codigopostaldomicilio	numeroclub	modalidad	categoria	discapacidad	numeroaccidentesaño	target	accidenteshistoricos	edad	temporada_federado	grupo_persona
0	59794	28232	07.28.000	B	Mayor Varón	NO	0.0	0	0.0	89	2020	Hombre
1	59794	28232	07.28.000	B	Mayor Varón	NO	0.0	0	0.0	90	2021	Hombre
2	3	28043	07.28.012	B	Mayor Varón	NO	0.0	0	0.0	88	2020	Hombre
3	12	28028	07.28.060	A	Mayor Mujer	NO	0.0	0	0.0	80	2020	Mujer
4	12	28028	07.28.060	A	Mayor Mujer	NO	0.0	0	0.0	81	2021	Mujer
...	...	...	...	...	...	...	...	...	...	...	...	...
121271	78946	28080	07.28.475	AU	Mayor Mujer	NO	0.0	0	0.0	28	2025	Mujer
121272	79253	28045	07.28.370	B	Mayor Mujer	NO	0.0	0	0.0	34	2025	Mujer
121273	78924	28016	07.28.000	C	Mayor Mujer	NO	0.0	0	0.0	22	2025	Mujer
121274	79882	46007	07.28.000	OT	Mayor Varón	NO	0.0	0	0.0	29	2025	Hombre
121275	79133	28039	07.28.370	C	Mayor Varón	NO	0.0	0	0.0	38	2025	Hombre

A las cuales separamos finalmente para poder avanzar con las transformaciones necesarias para avanzar con las transformaciones necesarias para crear un baseline que nos permita sentar las bases de las métricas de nuestras predicciones:

```
numericas = [
    "edad",
    "numeroaccidentesaño",
    "accidenteshistoricos",
    "temporada_federado"
]


categoricas = [
    "modalidad",
    "discapacidad",
    "grupo_persona",
    "numeroclub",
    "codigopostaldomicilio"
]
```



BASELINE

Con un modelo baseline simple y solo 7 variables disponibles, obtenemos un AUC de 0.68. Esto confirma que hay señal predictiva en los datos y justifica explorar modelos más complejos.


- Debido a que queremos predecir los siniestros priorizamos entonces el recall porque queremos minimizar falsos negativos y detectar el mayor número posible de perfiles de riesgo.
- Dado el desbalance y nuestro objetivo de maximizar recall, ajustamos el umbral de precisión para aumentar la detección de siniestros, asumiendo un incremento controlado de falsos positivos.



Se evaluaron distintos modelos de clasificación. **La regresión logística se utilizó como modelo baseline y mostró el mejor equilibrio entre rendimiento e interpretabilidad.** Random Forest y XGBoost no mejoraron el rendimiento global ni la capacidad de detectar la clase minoritaria (accidentes)


Por lo que se probó una optimización de hiperparámetros para mejorar la detección de siniestros, aunque **es posible que el dataset tenga un límite en su poder predictivo debido a la falta de variables clave que indiquen la actividad real del federado.**

- **Regresión Logística con GridSearchCV:** El modelo tiene capacidad moderada para distinguir entre federados que sufrirán un accidente y los que no.
- **Si tomamos un federado con accidente y uno sin accidente al azar, el modelo asignará una probabilidad mayor al accidentado aproximadamente el 68% de las veces.**



ODD RATIOS:

	coeficiente	odds_ratio
accidenteshistoricos	1.729432	5.637452
modalidad	0.452851	1.572789
grupo_persona_Mujer	-0.051980	0.949348
edad	-0.283905	0.752838
grupo_persona_Juvenil Hombre	-0.706072	0.493579
grupo_persona_Juvenil Mujer	-0.719951	0.486776
grupo_persona_Niño/a Mujer	-1.841348	0.158604
grupo_persona_Niño/a Hombre	-2.218026	0.108824



HISTORIAL DE ACCIDENTES

El historial de accidentes aparece como el **predictor más fuerte**: cada accidente previo multiplica aproximadamente por 5.6 las probabilidades de sufrir un nuevo accidente.



MODALIDAD

La modalidad de federación también aumenta el riesgo (57%), mientras que la edad y ciertos grupos demográficos se asocian con menor probabilidad de accidente.



PODEMOS INFERIR

El modelo no permite predecir accidentes con alta precisión individual, pero sí identifica patrones de riesgo poblacional, lo que podría ayudar a priorizar acciones de prevención.




ALGUNAS CONCLUSIONES

- Tras probar múltiples algoritmos (Logistic Regression, Random Forest y XGBoost) y optimizar sus hiperparámetros mediante GridSearchCV con validación por grupos, todos los modelos convergieron en un rendimiento similar (ROC AUC $\approx$ 0.68–0.69). Este resultado sugiere que **el rendimiento del modelo está principalmente limitado por la información disponible en las variables del dataset, más que por la elección del algoritmo.**


- **Las variables utilizadas** capturan factores generales de riesgo (edad, historial de accidentes y modalidad de federación), pero probablemente **no incluyen información más específica sobre exposición al riesgo o nivel técnico**, lo que limitaría la capacidad predictiva del modelo.




PRÓXIMOS PASOS



**CONSEGUIR MÁS
FEATURES**



FEATURE ENGINEERING



**USO DE LAS
CONCLUSIONES PARA
OTROS DEPARTAMENTOS**



GRACIAS POR LA ATENCIÓN

